FIAP

PÓS TECH
Análise de Dados

TECH CHALLENGE

FASE 2

Alan (@xxxxxx), Derick (@xxxxxx), Gustavo (@xxxxxx), Tais (@xxxxxx), Victor (@xxxxxx)

FIAP

POS TECH

SÚMARIO

SUMÁRIO

O caminho da evidência até a recomendação

01 Introdução e objetivo
02 Entendimento da base e desequilíbrio das classes
03 Análise exploratória e seleção de variáveis
04 Preparação e experimentos
05 Comparação de modelos e trade-offs
06 Random Forest: decisão e próximos passos

FIAP

PÓS TECH

INTRODUÇÃO

INTRODUÇÃO

A avaliação sensorial é essencial, mas pode ser apoiada por dados físico-químicos.

O DESAFIO

Antecipar a classificação da qualidade do vinho a partir de medições laboratoriais.

O OBJETIVO

Classificar alta qualidade (nota ≥ 7) versus baixa/média qualidade (nota < 7).

FIAP

POS TECH

ANALISE EXPLORATORIA

COMO A ANÁLISE FOI CONSTRUÍDA

Etapas exigidas no desafio e implementadas no notebook.

1. Entendimento do problema e criação do alvo binário
2. Exploração: distribuição, correlações e outliers
3. Separação treino/teste (80/20) e escalonamento
4. Balanceamento da classe minoritária com SMOTE
5. Treinamento, avaliação e interpretação dos modelos

METODOLOGIA

O QUE EXISTE NO DATASET?

1.143 amostras • 11 propriedades físico-químicas • nota de qualidade • identificador

Acidez fixa: ácidos não voláteis • Acidez volátil: ácidos voláteis

Ácido cítrico: componente de acidez • Açúcar residual: açúcar remanescente

Cloretos: teor de sais • SO_2 livre: dióxido de enxofre disponível

SO_2 total: frações livre e combinada • Densidade: massa por volume

pH: intensidade da acidez • Sulfatos: sais relacionados à conservação

Álcool: teor alcoólico • Quality: nota atribuída por especialistas

Id: identificador, não utilizado como variável preditora

O PRIMEIRO PROBLEMA: CLASSES DESIGUAIS

Notas 7–8 são menos frequentes que notas 3–6.

EVIDÊNCIA DO NOTEBOOK

Contagem por nota e por classe binária, histogramas e countplots identificaram forte desbalanceamento.

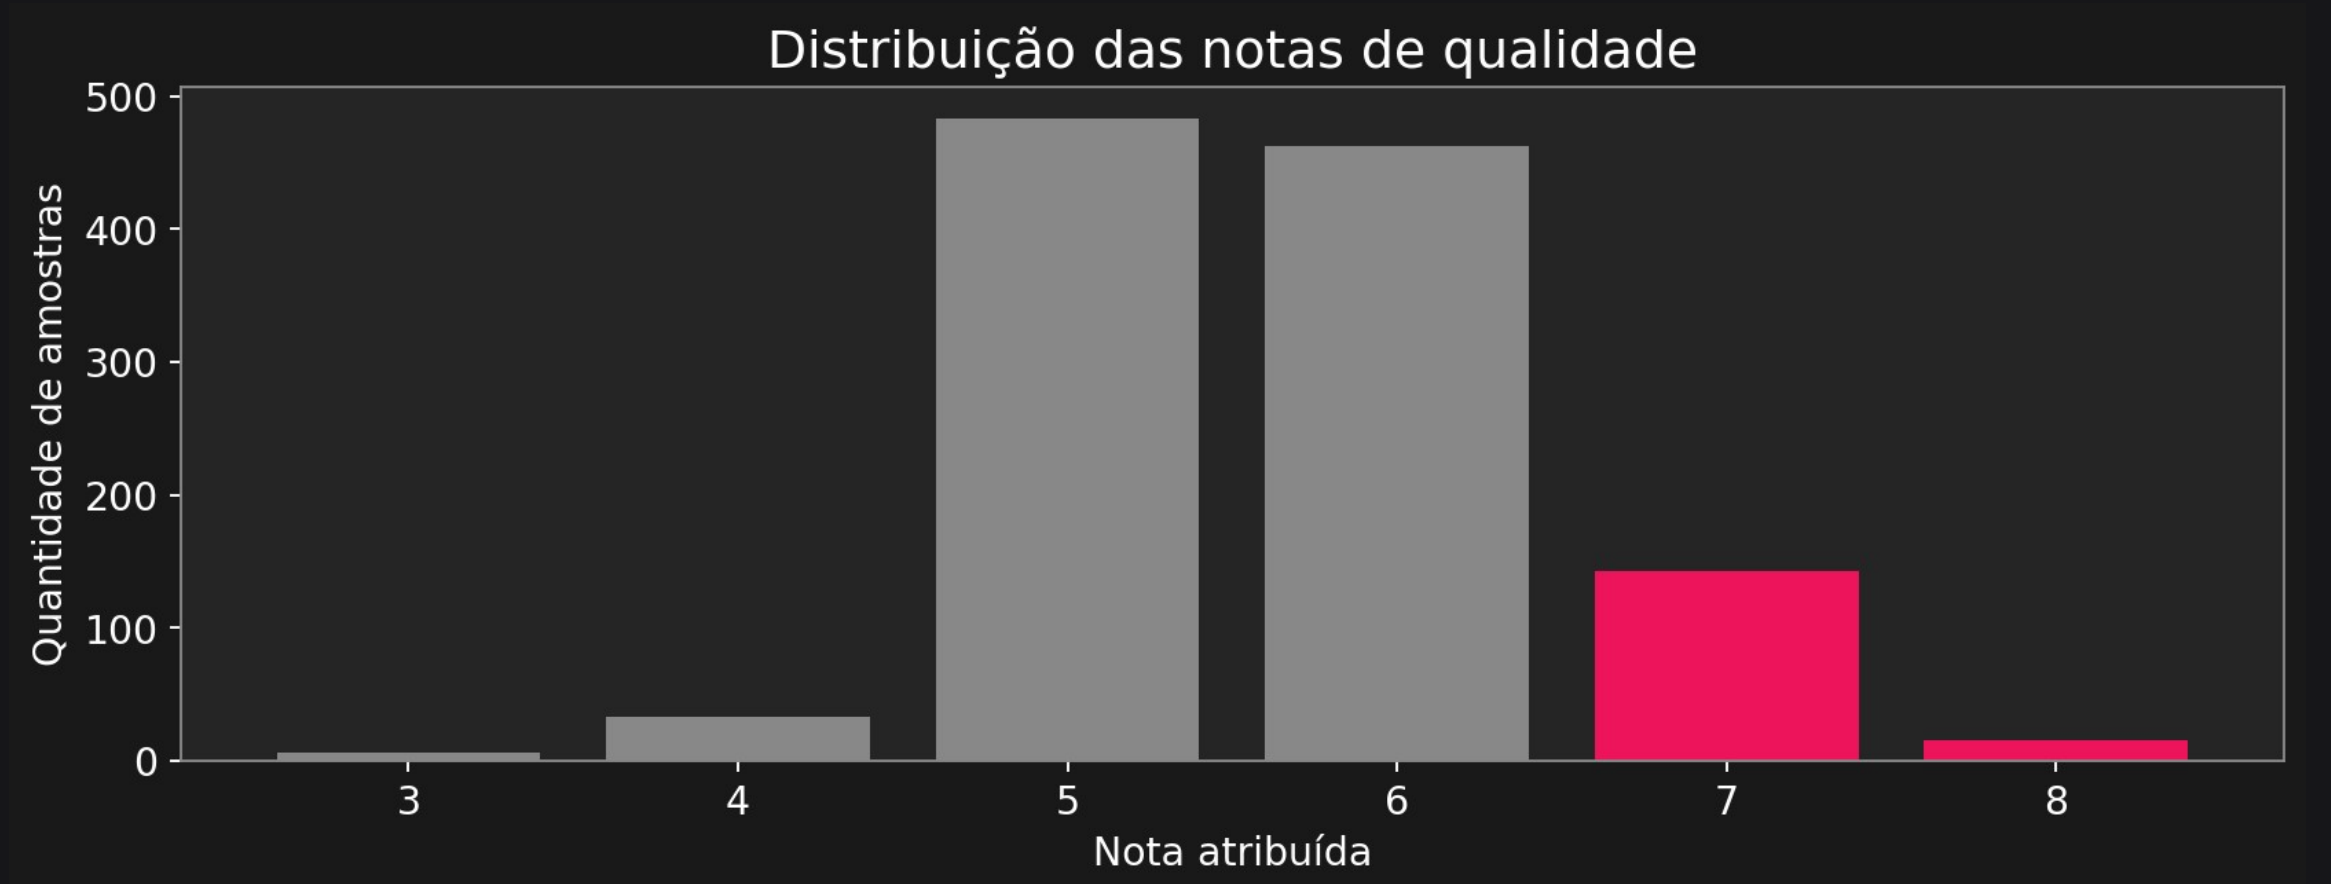
IMPLICAÇÃO

Um modelo que prevê apenas “baixa/média” pode ter acurácia alta e não reconhecer nenhum vinho especial.

EXPLORAÇÃO

A MAIORIA DOS VINHOS NÃO É DE ALTA QUALIDADE

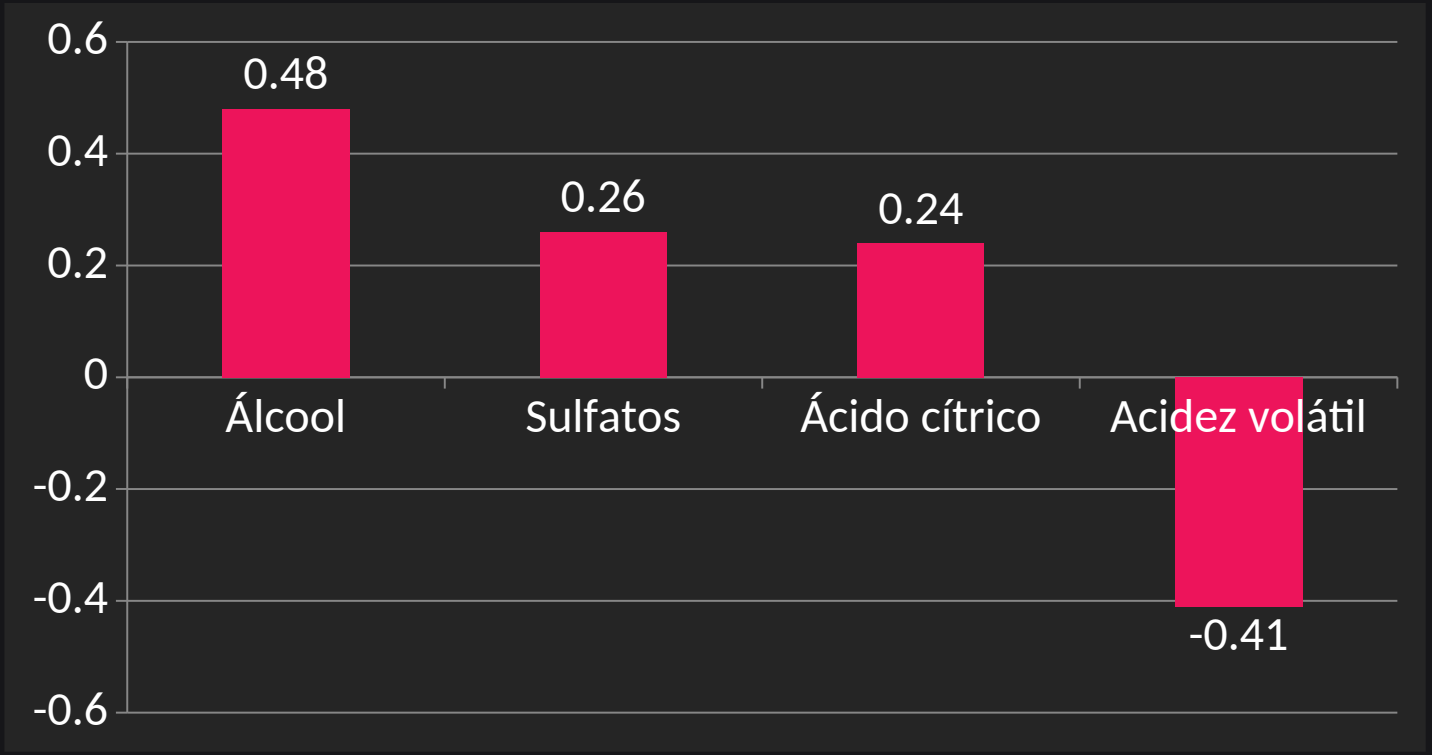
984 amostras com notas 3–6 versus 159 com notas 7–8



Fonte: WineQT.csv • classificação binária: nota ≥ 7

QUAIS CARACTERÍSTICAS SINALIZAM QUALIDADE?

Correlação de Pearson com a nota original “quality”, calculada no notebook.

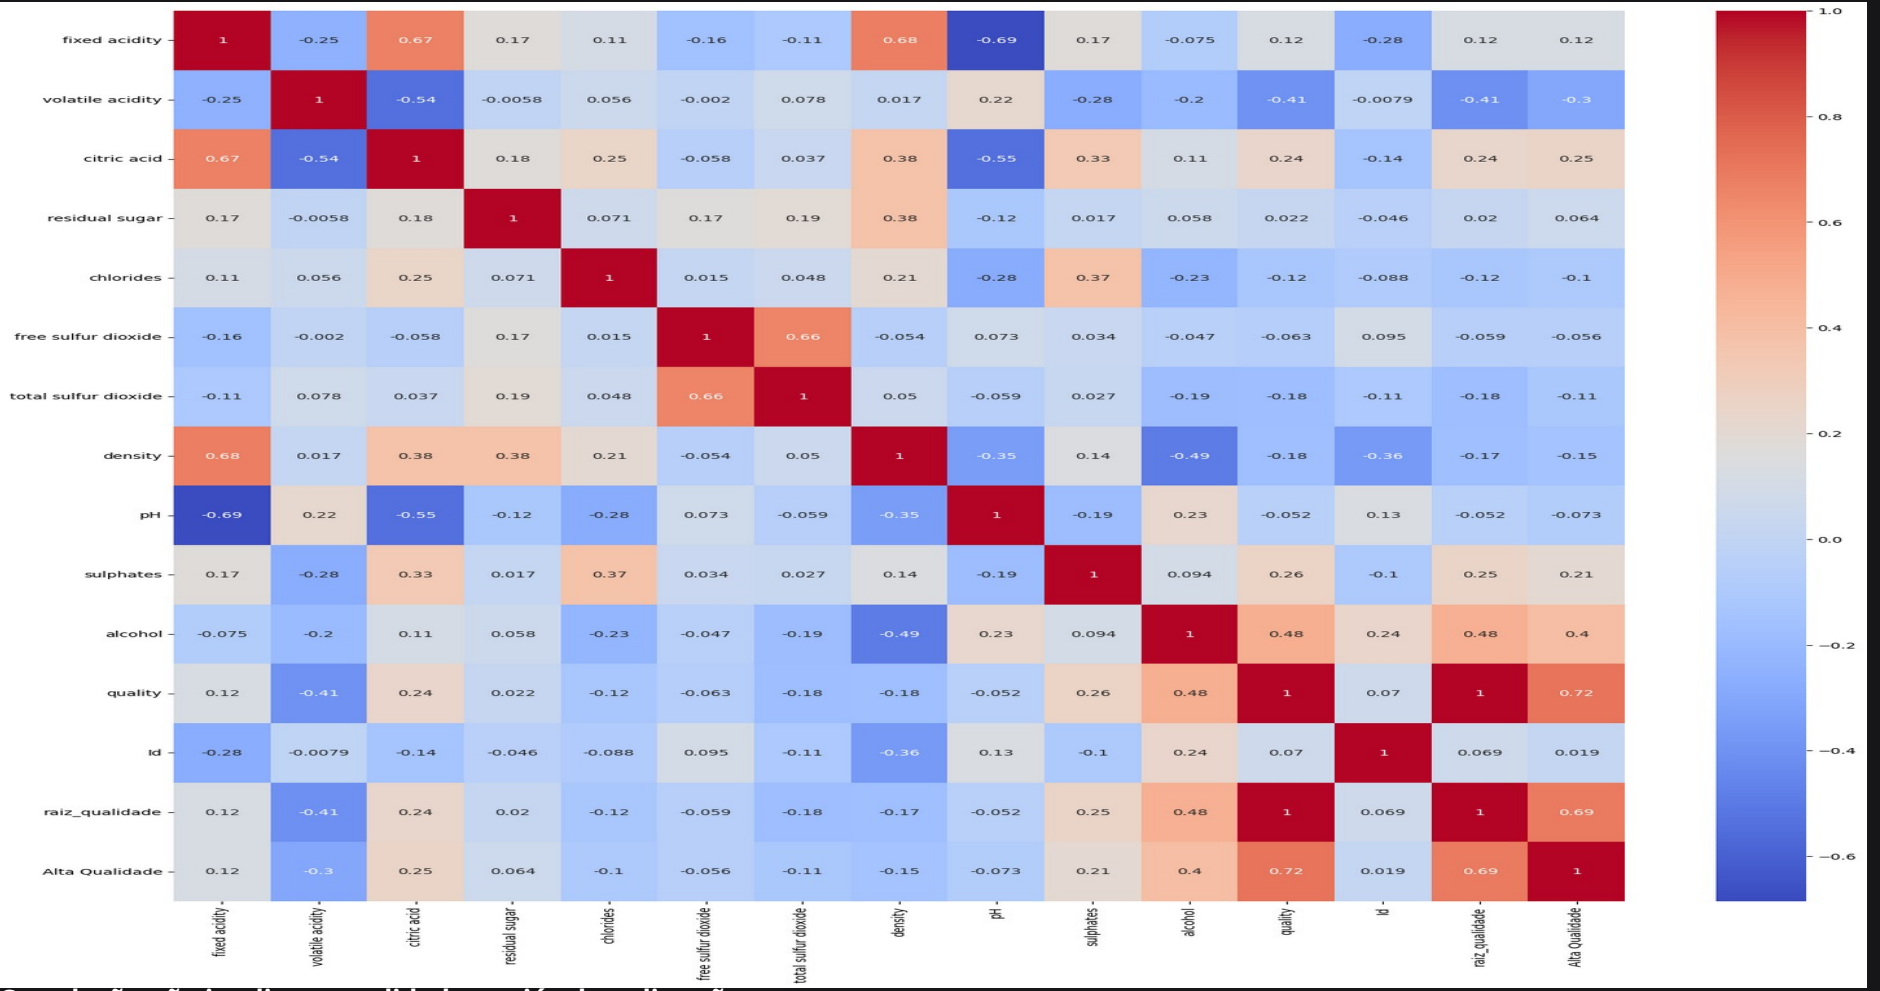


LEITURA EXECUTIVA

Álcool (+0,48) e acidez volátil (−0,41) mostram as associações mais fortes. Sulfatos (+0,26) e ácido cítrico (+0,24) complementam o sinal.

A MATRIZ DE CORRELAÇÃO REVELA AS RELAÇÕES

Primeiro avaliamos todas as variáveis; depois selecionamos as quatro mais relacionadas à nota.



Correlação não implica causalidade; variável quality não entra como preditora.

POR QUE ESTAS QUATRO VARIÁVEIS?

Da matriz de correlação à seleção das entradas do modelo.

EVIDÊNCIA

O notebook calculou a matriz de Pearson e examinou dispersões de quality × alcohol, volatile acidity, sulphates e citric acid.

DECISÃO DE MODELAGEM

X = [volatile acidity, alcohol, sulphates, citric acid]. A seleção reflete associações exploratórias; não comprova causalidade nem importância preditiva isolada.

OS BOXPLOTS MOSTRAM VALORES EXTREMOS

A dispersão e os outliers justificam avaliar diferentes estratégias de preparação.



OUTLIERS: O DADO NÃO É PERFEITO

Boxplots foram utilizados para investigar valores extremos.

ACHADO

O notebook relata muitos outliers em acidez fixa, cloretos, sulfatos e açúcar residual.

CONSEQUÊNCIA

É importante comparar abordagens com comportamentos distintos diante de valores extremos e relações não lineares.

COMO GARANTIMOS UMA COMPARAÇÃO JUSTA?

Separação e transformações documentadas no notebook.

80% TREINO / 20% TESTE • random_state = 99

MinMaxScaler e StandardScaler ajustados no treino

SMOTE aplicado à classe minoritária no treino

O mesmo conjunto de teste foi utilizado para avaliar as previsões

POR QUE ACURÁCIA NÃO BASTA?

O foco é encontrar os vinhos de alta qualidade.

RECALL — ALTA

Dos vinhos realmente bons, quantos o modelo encontra? Evita perder oportunidades.

F1 — ALTA

Equilibra a identificação dos vinhos bons com a confiabilidade dos alertas.

FIAP

POS TECH

MODELOS DE MACHINE LEARNING

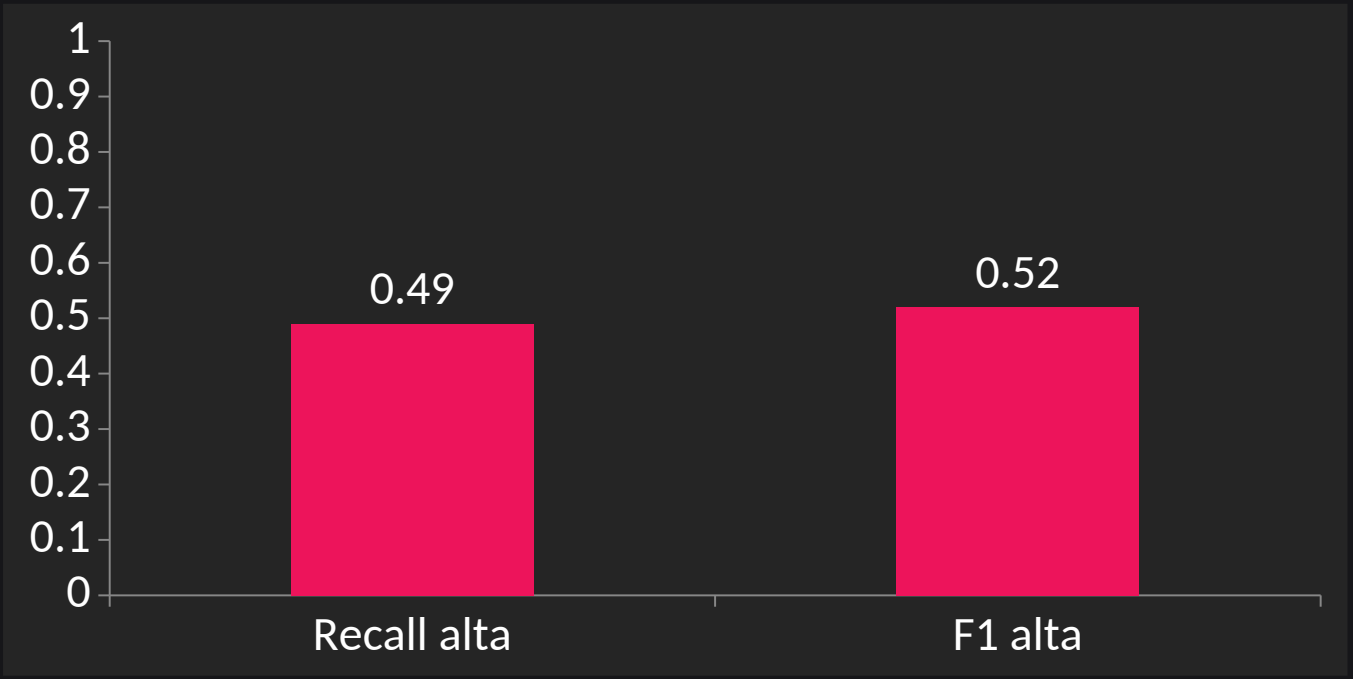
QUAIS MODELOS FORAM TESTADOS?

Do baseline a modelos capazes de representar relações complexas.

- **Dummy: referência mínima (classe majoritária)**
- **KNN: semelhança entre amostras**
- **Naive Bayes: abordagem probabilística**
- **Regressão logística: referência linear e interpretável**
- **Random Forest: conjunto de árvores para padrões não lineares**

O KNN MELHOROU, MAS AINDA PERDE VINHOS

Resultados relatados na conclusão do notebook para KNN com balanceamento e normalização.



INTERPRETAÇÃO

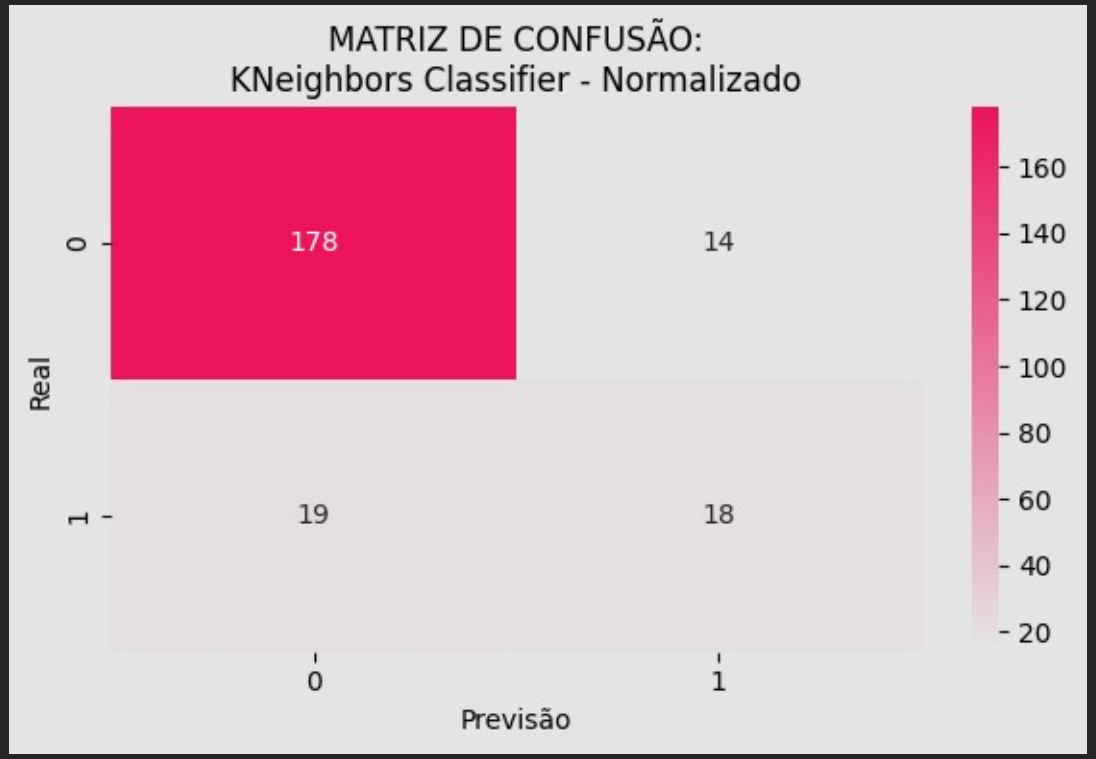
Recall de 49% significa que mais da metade dos vinhos de alta qualidade ainda não é reconhecida.

PÚBLICO

MATRIZ DE CONFUSÃO + CLASSIFICATION REPORT

KNN balanceado

MATRIZ DE CONFUSÃO



CLASSIFICATION REPORT

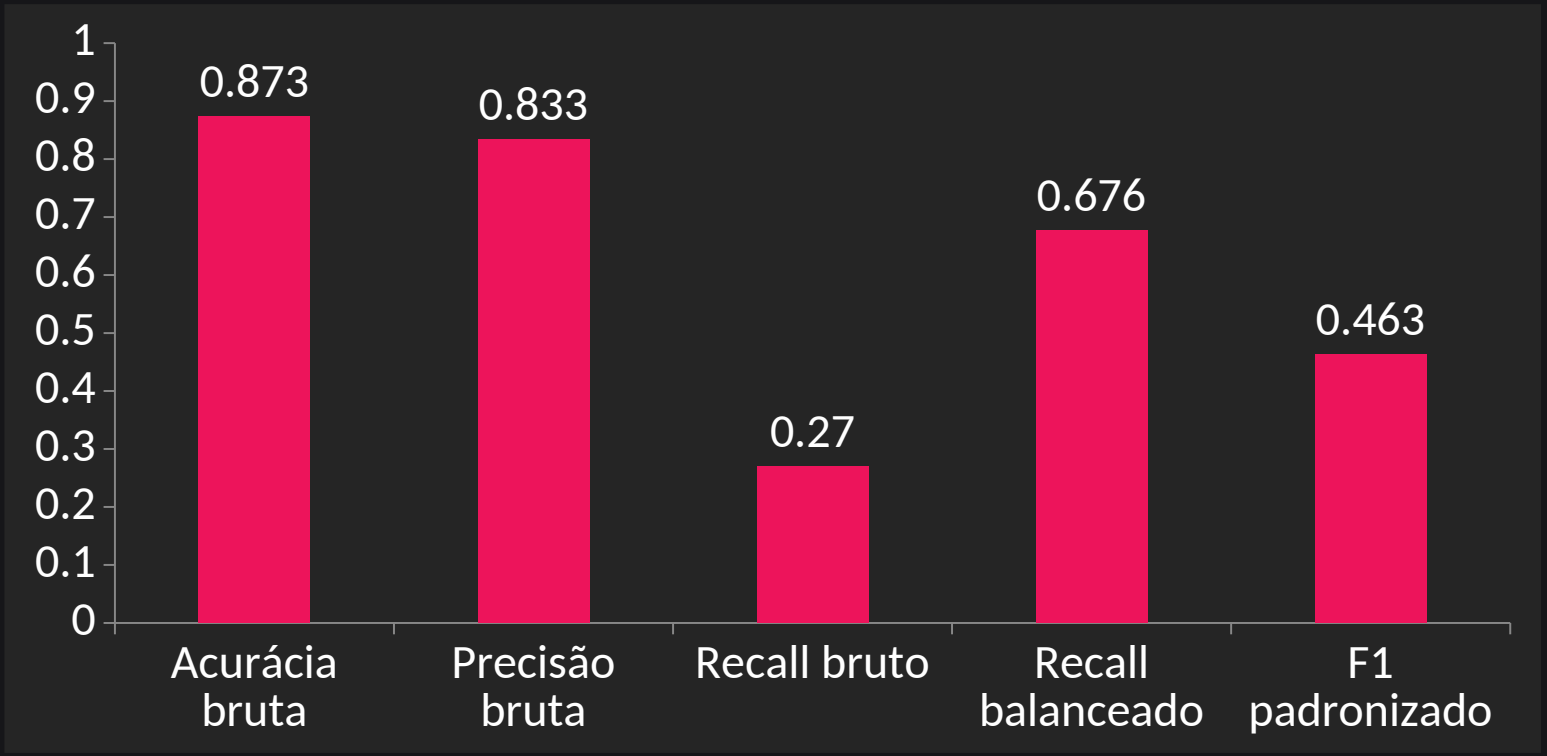
Classe	Precisão	Recall	F1	Suporte
Baixa	0.90	0.93	0.92	192
Alta	0.56	0.49	0.52	37

Acurácia: 85.6% | Teste: 229 amostras

PÚBLICO

REGRESSÃO LOGÍSTICA: O TRADE-OFF

Dados brutos favorecem precisão; balanceamento aumenta a captura.



EVIDÊNCIA

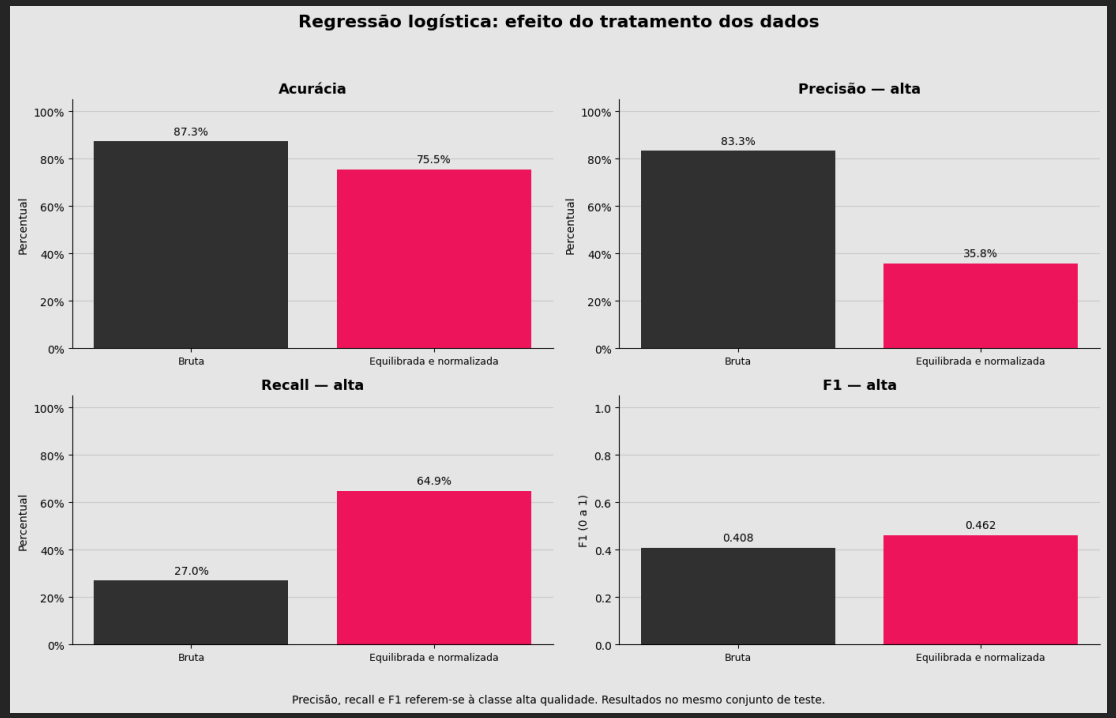
Base bruta: 87,3% acurácia, mas apenas 27% recall. Balanceada: recall até 67,6%; melhor F1 relatado: 0,463.

PÚBLICO

MATRIZ DE CONFUSÃO + CLASSIFICATION REPORT

Regressão logística balanceada

MATRIZ DE CONFUSÃO



CLASSIFICATION REPORT

Classe	Precisão	Recall	F1	Suporte
Baixa	0.92	0.78	0.84	192
Alta	0.36	0.65	0.46	37

Acurácia: 75.5% | Teste: 229 amostras

Fonte: reprodução dos parâmetros do notebook sobre WineQT.csv • mesma divisão treino/teste (random_state=99)

PÚBLICO

O RANDOM FOREST ENTRA NA DISPUTA

Uma floresta de árvores consegue representar interações não lineares.

POR QUE TESTAR?

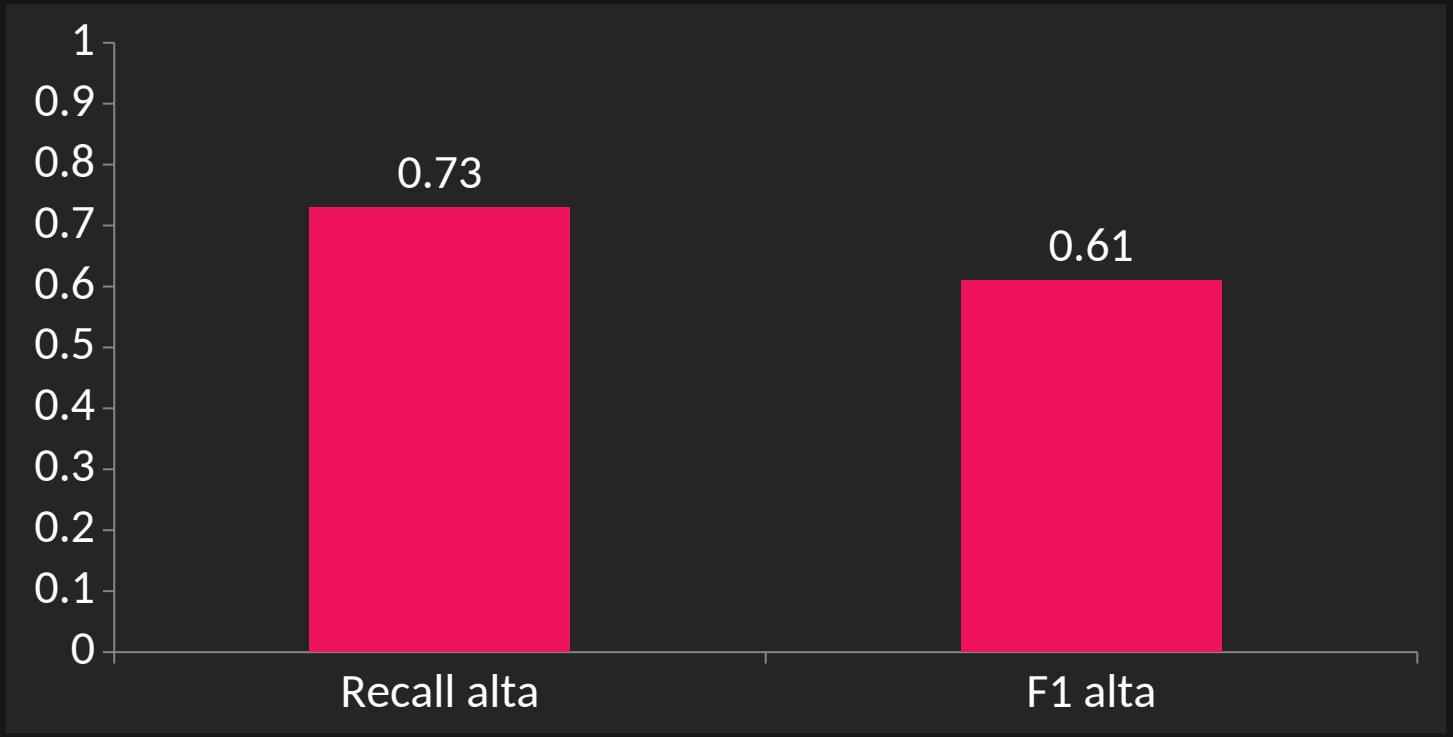
As propriedades químicas podem atuar conjuntamente; a relação com a qualidade não precisa ser linear.

COMO FOI AVALIADO?

O notebook compara a versão bruta e a versão balanceada/normalizada e explora ajuste do limiar de decisão.

O AJUSTE QUE MUDOU A DECISÃO

Random Forest com base balanceada e limiar 0,40 — conclusão registrada no notebook.



RESULTADO REPORTADO

73% de recall e 61% de F1 para alta qualidade. A mudança do limiar favorece a captura da classe prioritária.

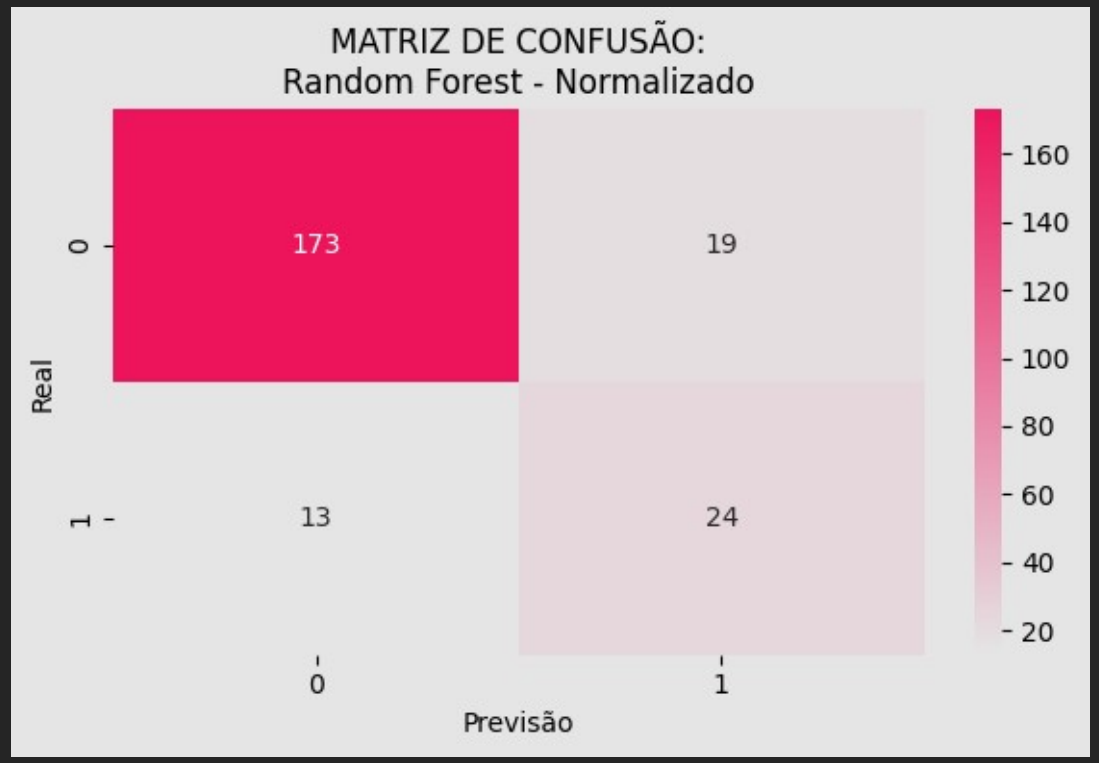
PÚBLICO

COMPARAÇÃO

MATRIZ DE CONFUSÃO + CLASSIFICATION REPORT

Random Forest balanceado

MATRIZ DE CONFUSÃO



CLASSIFICATION REPORT

Classe	Precisão	Recall	F1	Suporte
Baixa	0.93	0.90	0.92	192
Alta	0.56	0.65	0.60	37

Acurácia: 86.0% | Teste: 229 amostras

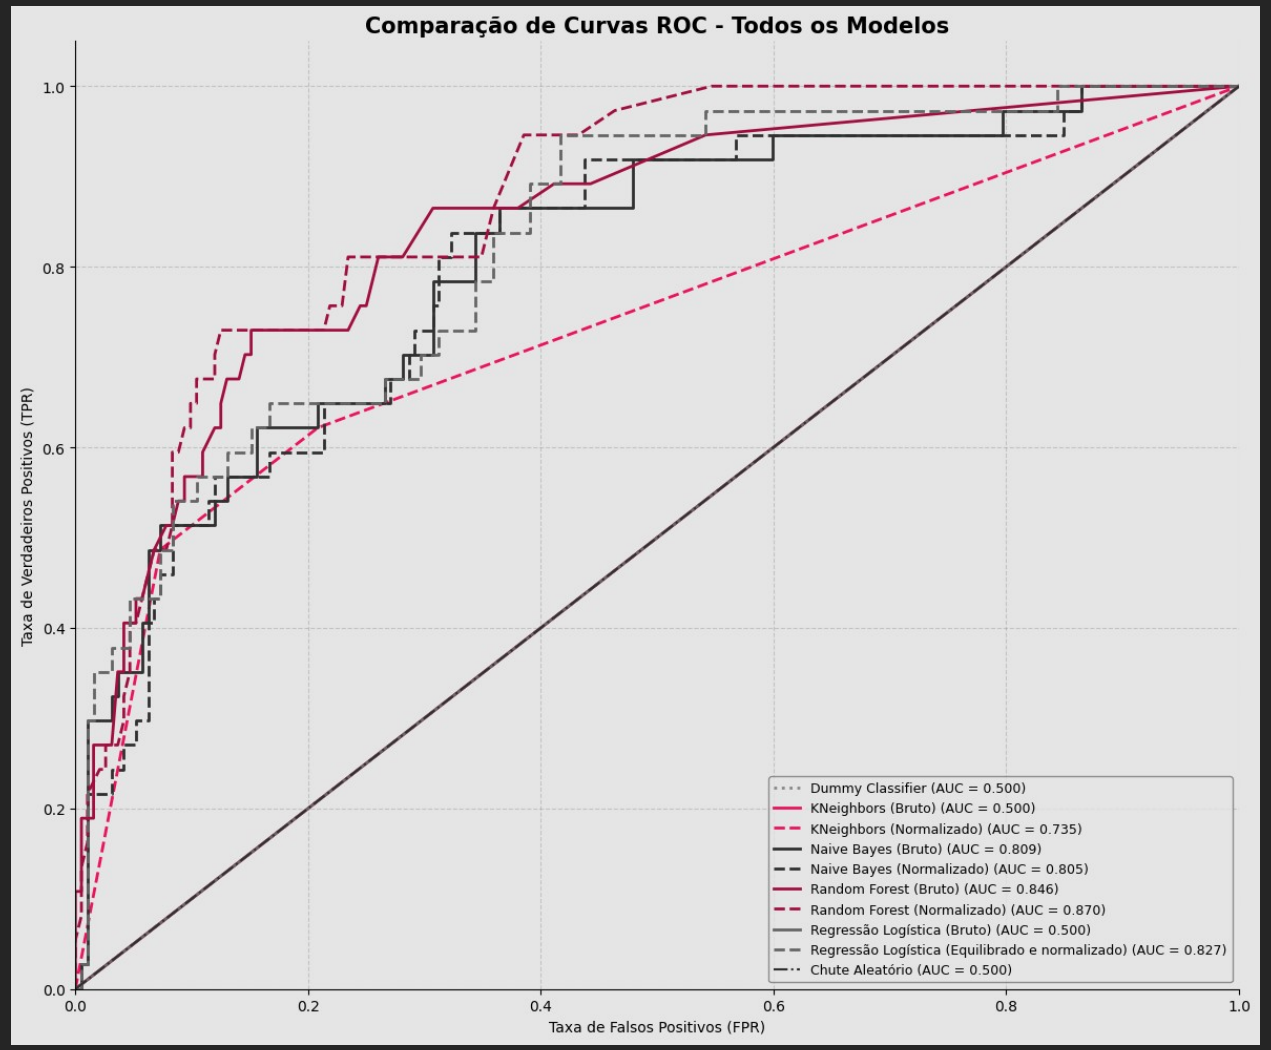
Fonte: reprodução dos parâmetros do notebook sobre WineQT.csv • mesma divisão treino/teste (random_state=99)

PÚBLICO

PÚBLICO

Comparação de Curvas ROC – Todos os Modelos

Comparação da classe positiva (nota ≥ 7), calculada na mesma base de teste.

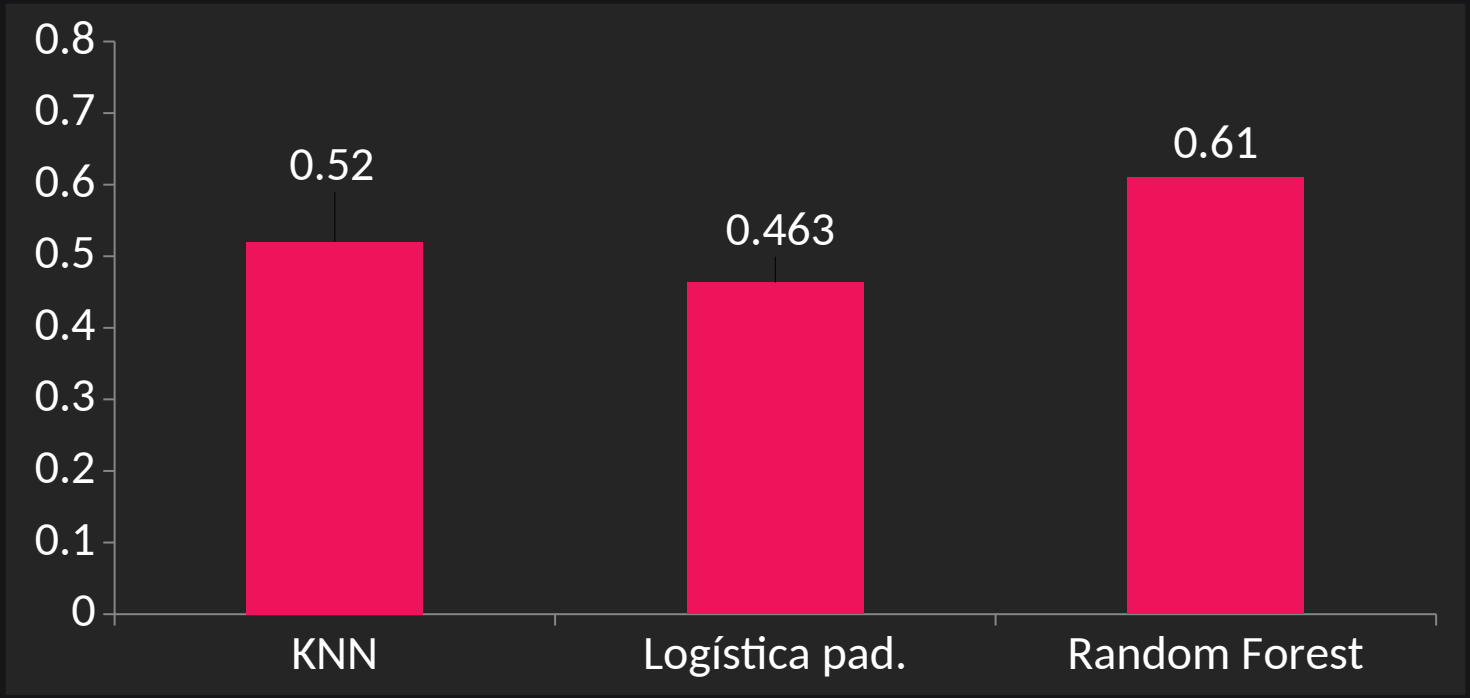


Random Forest limiar otimizado	Precisão 53%	Recall 73%	F1 61%
Random Forest balanceado	Precisão 56%	Recall 65%	F1 60%
KNN balanceado	Precisão 56%	Recall 49%	F1 52%
Naive Bayes bruto	Precisão 53%	Recall 51%	F1 52%
Random Forest bruto	Precisão 60%	Recall 41%	F1 48%
Regressão logística balanceada	Precisão 36%	Recall 65%	F1 46%
KNN bruto	Precisão 67%	Recall 32%	F1 44%
Naive Bayes balanceado	Precisão 32%	Recall 65%	F1 43%
Regressão logística bruta	Precisão 83%	Recall 27%	F1 41%
Dummy	Precisão 0%	Recall 0%	F1 0%

PÚBLICO

A COMPARAÇÃO QUE SUSTENTA A ESCOLHA

Indicadores da classe de alta qualidade, conforme conclusões do notebook.



F1 DA CLASSE ALTA

KNN ≈ 0,52

Logística padronizada ≈ 0,463

Random Forest ajustado ≈ 0,61

O QUE ESSA ESCOLHA PERMITE?

Apoio antecipado à decisão, sem substituir especialistas.

CONTROLE DE QUALIDADE

Triagem de lotes com base em medidas físico-químicas.

PROCESSO PRODUTIVO

Acompanhar álcool e acidez volátil, com validação enológica.

POSICIONAMENTO

Apoiar decisões sobre lotes premium após validação operacional.

RECOMENDAÇÃO EXECUTIVA

Selecionar Random Forest como candidato prioritário para validação.

POR QUE RANDOM FOREST?

Melhor F1 reportado entre os resultados destacados e recall de 73% para vinhos de alta qualidade, com limiar ajustado.

PRÓXIMOS PASSOS

Validar em amostras externas, monitorar falsos positivos, calibrar limiar e medir importância das variáveis.

FONTES, ESCOPO E LIMITAÇÕES

Transparência sobre a origem das evidências.

Fonte: tech_challenge_02.py (notebook fornecido)

Regras: POSTECH – DTAT – Tech Challenge – Fase 2

Base citada: Wine Quality Dataset (Kaggle)

Gráficos desta apresentação foram reconstruídos com os números explicitados no notebook; não houve reexecução sem o arquivo WineQT.csv. Correlação não demonstra causalidade. Métricas finais de Random Forest são as declaradas na conclusão do notebook.